Интерпретация последовательностей ДНК и РНК с помощью машинного обучения

Аристова Елизавета Олеговна

МНС ИоГен РАН

МНС центр ИИ МГУ

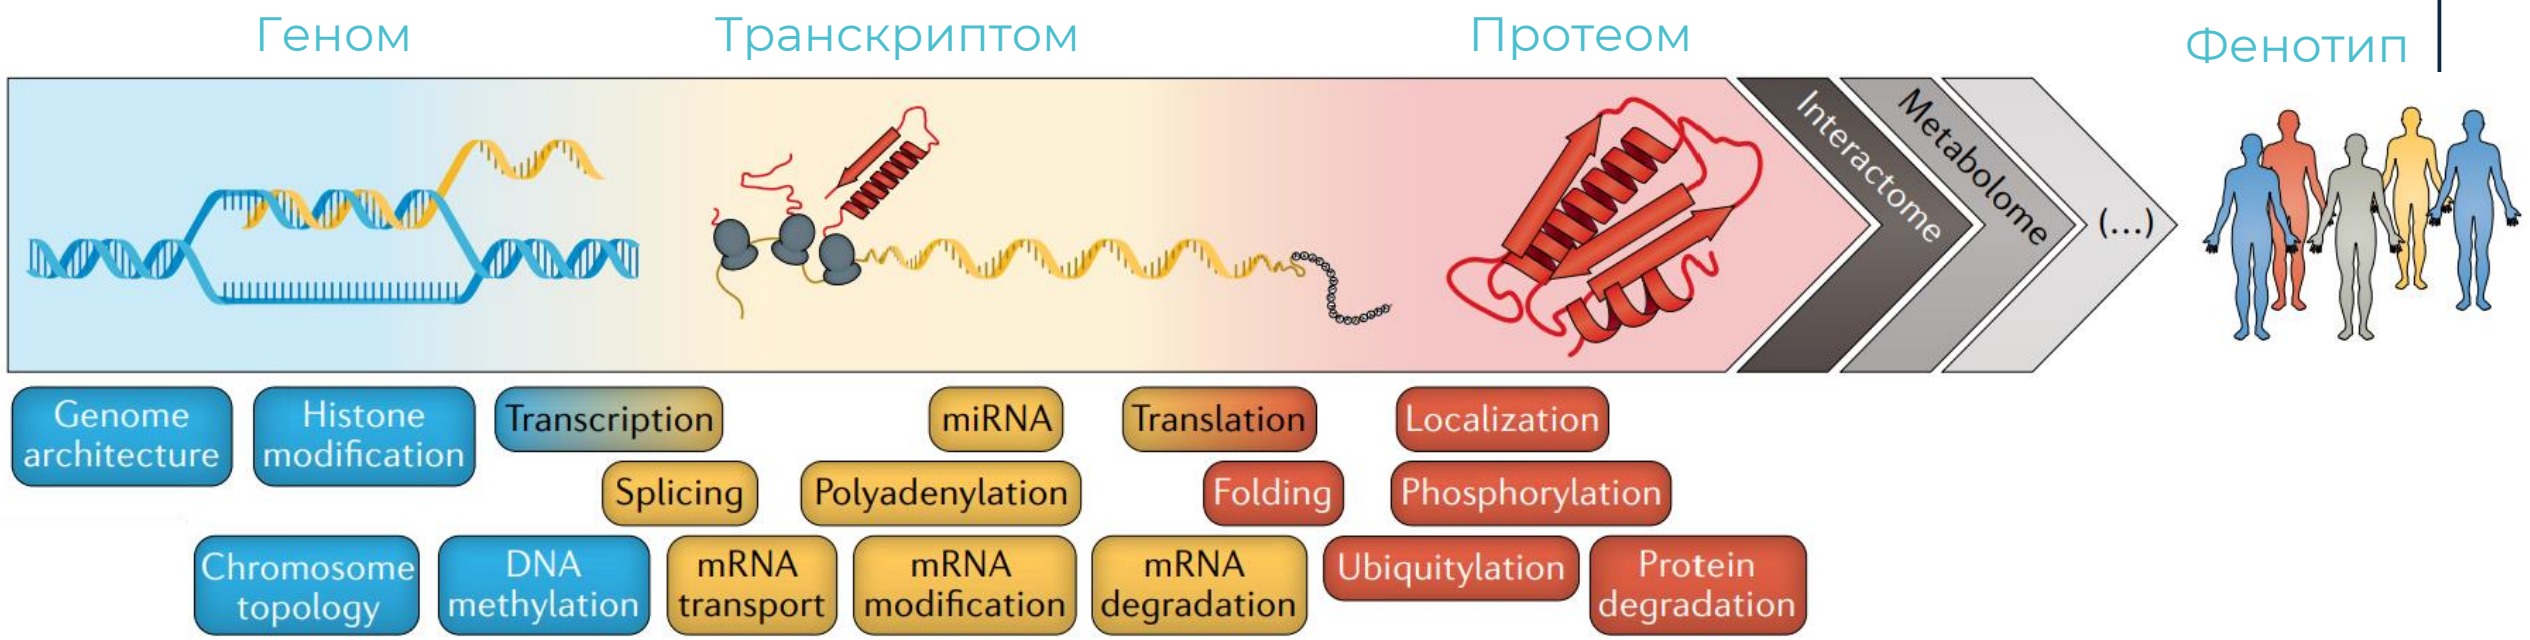
Преподаватель ФББ МГУ

Сириус
научно-технологический университет

2026

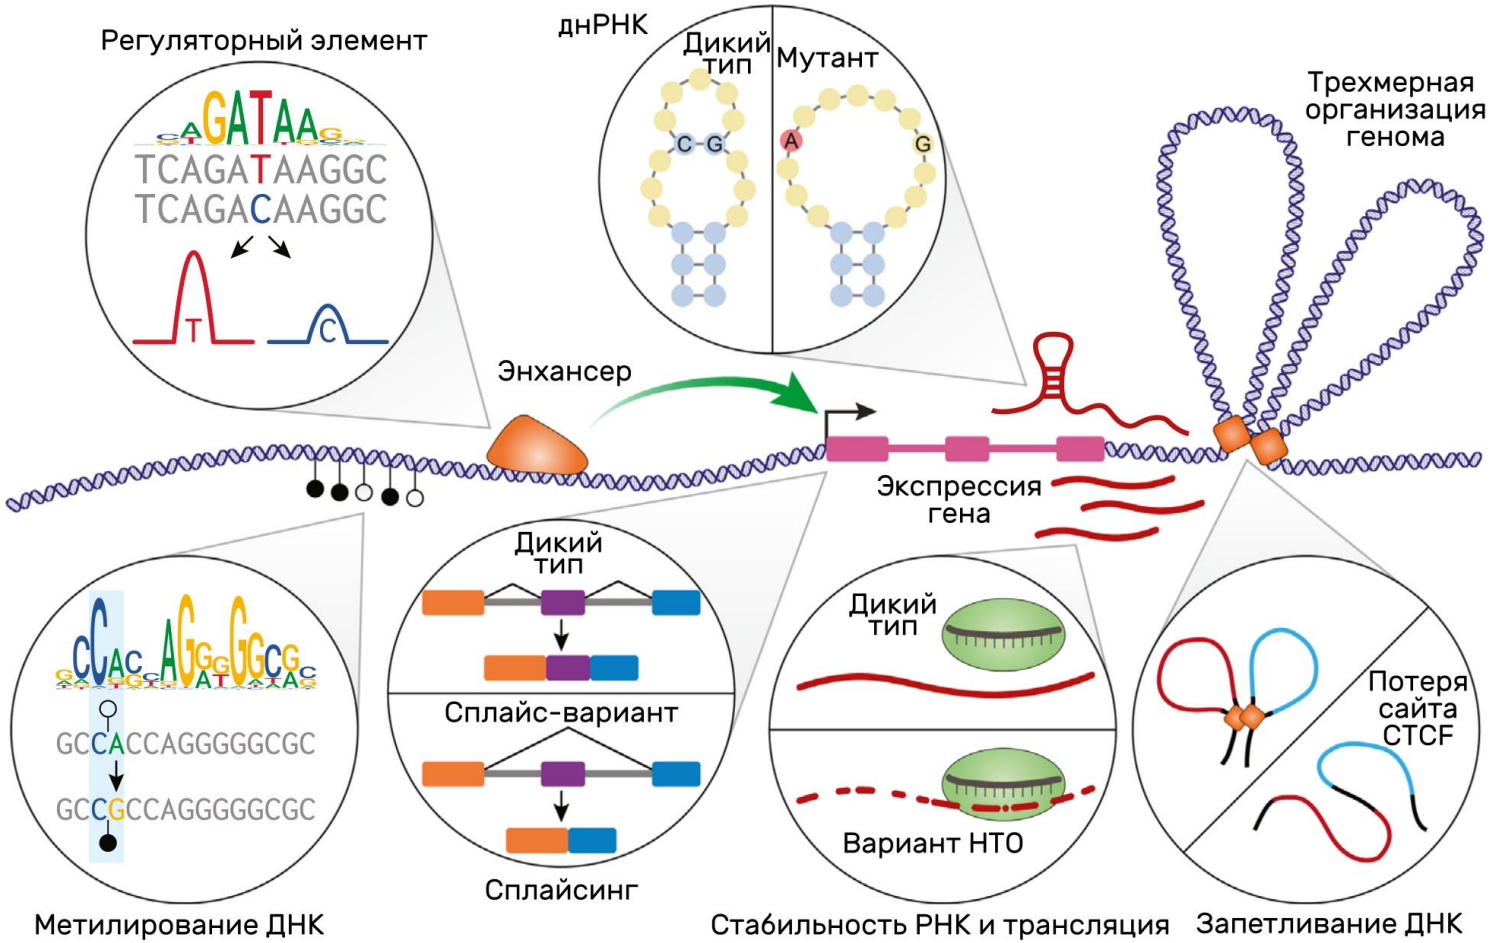
0 · Зачем нужны модели в геномике

От генотипа к фенотипу



Buccitelli and Selbach, Nature Reviews Genetics, 2020

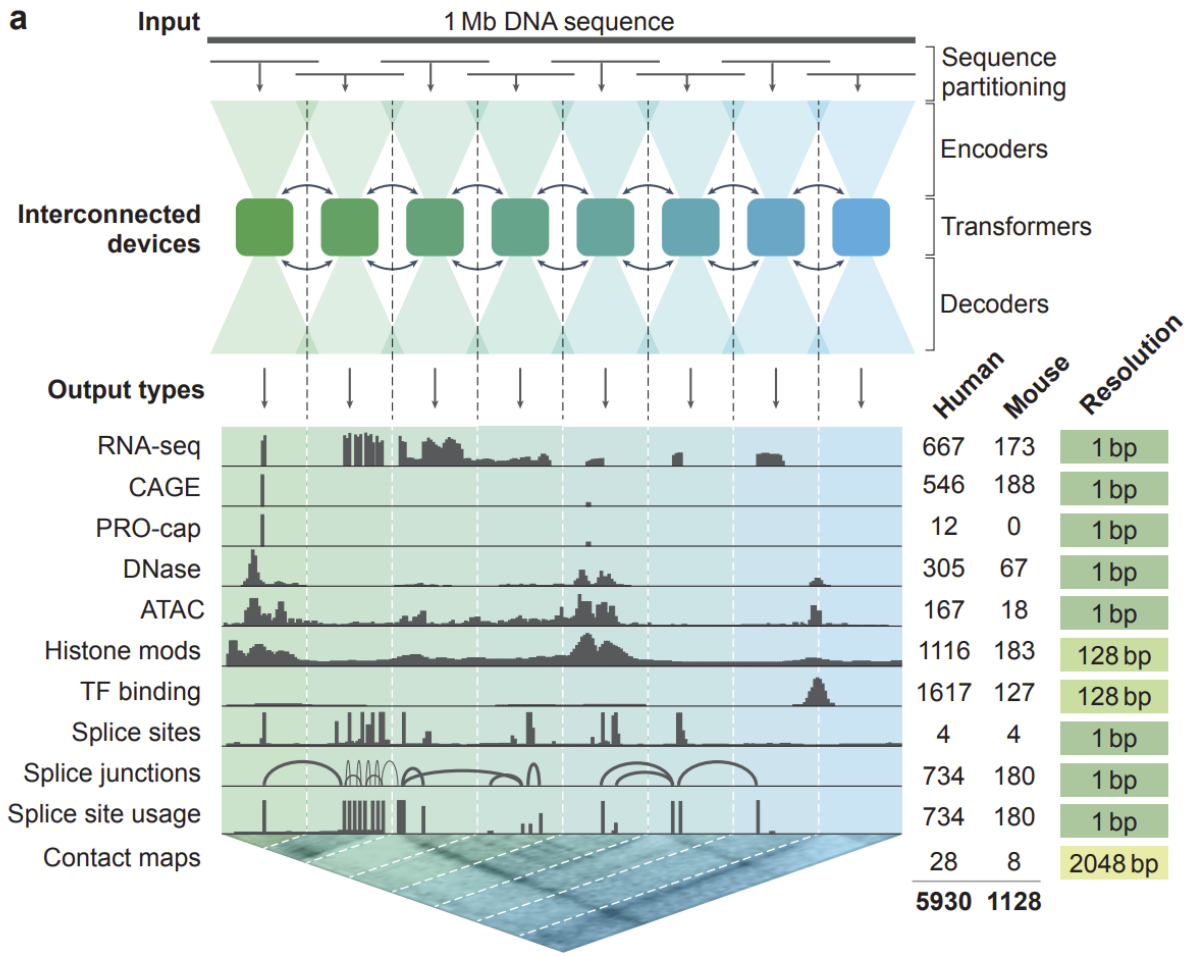
Мутации затрагивают разные уровни регуляции, но проводить эксперимент каждый раз дорого



Сириус
научно-технологический университет

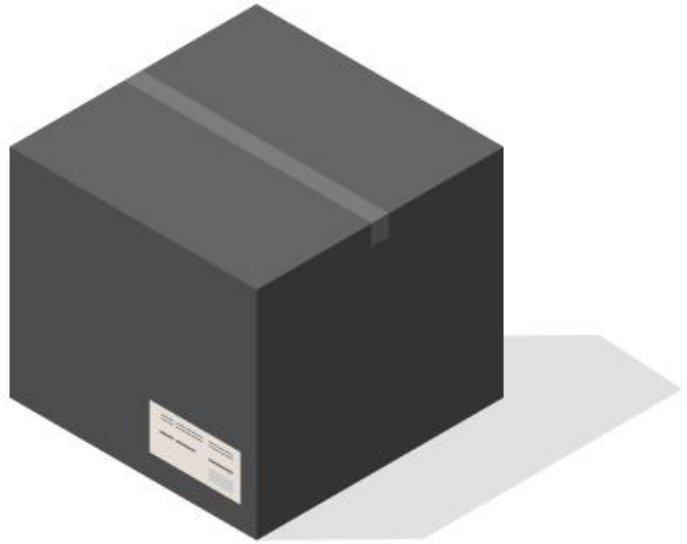
Насколько можно доверять предсказаниям модели?

- Модели выявляют закономерности в генетических последовательностях и предсказывают их функциональные эффекты
- Высокая предсказательная точность сама по себе не гарантирует обоснованность конкретного результата
- При отсутствии экспериментальной валидации ключевой вопрос — насколько предсказание устойчиво, согласуется с независимыми данными и известными биологическими механизмами.



Сириус
научно-технологический университет

Насколько можно доверять предсказаниям модели?



“Черный ящик”

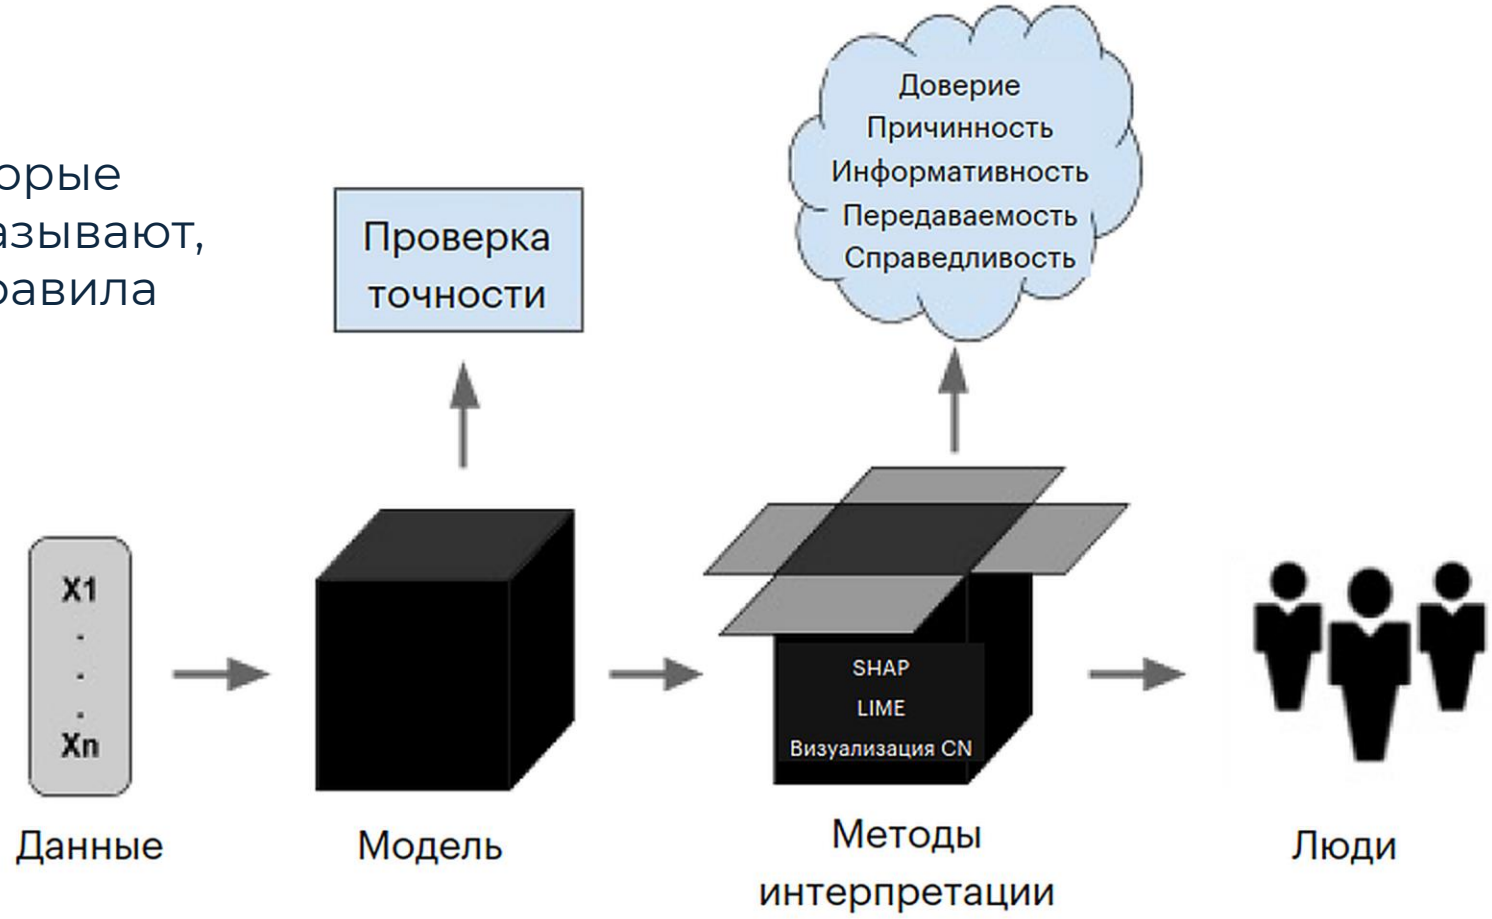
внутреннее устройство сложно интерпретировать напрямую, видим только входы и выходы

01 · Что такое интерпретация и зачем она нужна

Определения · мотивация · примеры из медицины

Интерпретируемость — способность объяснить, почему модель приняла именно такое решение

Explainable AI (XAI) — методы, которые «открывают» чёрный ящик и показывают, какие признаки, примеры или правила определили ответ модели



Сириус
научно-технологический университет

Зачем нужна интерпретация

01

Доверие и внедрение

- Врач и биолог видят, на чём основан прогноз
- Требование FDA для медицинских ИИ
- Прозрачность для экспертов и пациентов

02

Отладка и надёжность

- Поиск ложных признаков до релиза
- Модель учит биологию — или артефакты данных?
- Диагностика сбоев на конкретных примерах

03

Научные открытия

- Гипотезы о регуляторном коде генома
- Новые мотивы и элементы из аттрибуций
- Закономерности, которые люди пропустили

Классика: волк или хаски?

- Классификатор «волк vs хаски» — высокая точность на тесте
- Все фото волков со снегом, а хаски — без снега
- LIME показал, что модельсмотрит на снег, а не животное

Ribeiro et al., «Why Should I Trust You?» · KDD 2016



(a) Husky classified as wolf (b) Explanation

Figure 11: Raw data and explanation of a bad model's prediction in the "Husky vs Wolf" task.

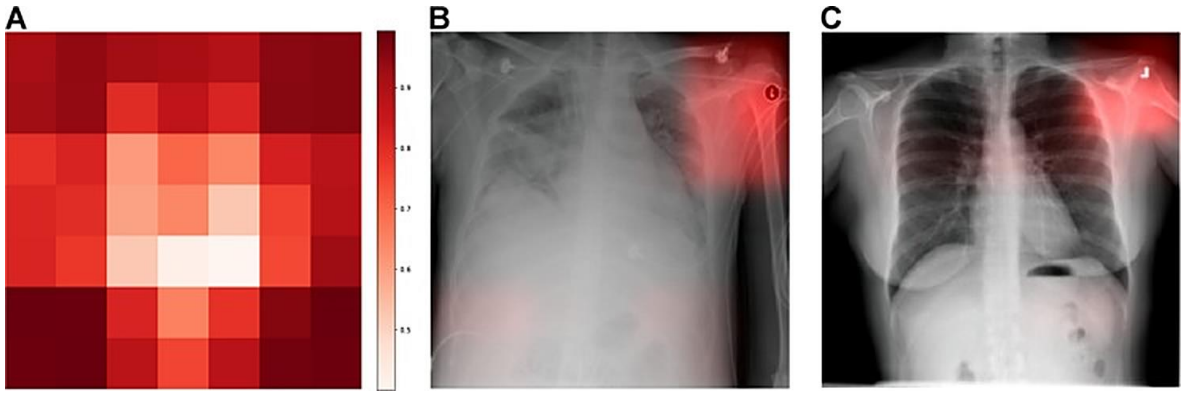
Правильный ответ ≠ правильные причины

Shortcut learning — «эффект умного Ганса»

- Модель идёт по «короткому пути» и ищет побочный признак вместо настоящего
- Работает на тесте, но ломается при смене условий (domain shift)
- Модель читает артефакты разметки
- Обнаружить это можно, только заглянув внутрь модели

Известные примеры

Пневмоторакс: сигнал — маркеры-линейки на рентгене (Zech et al., 2018)



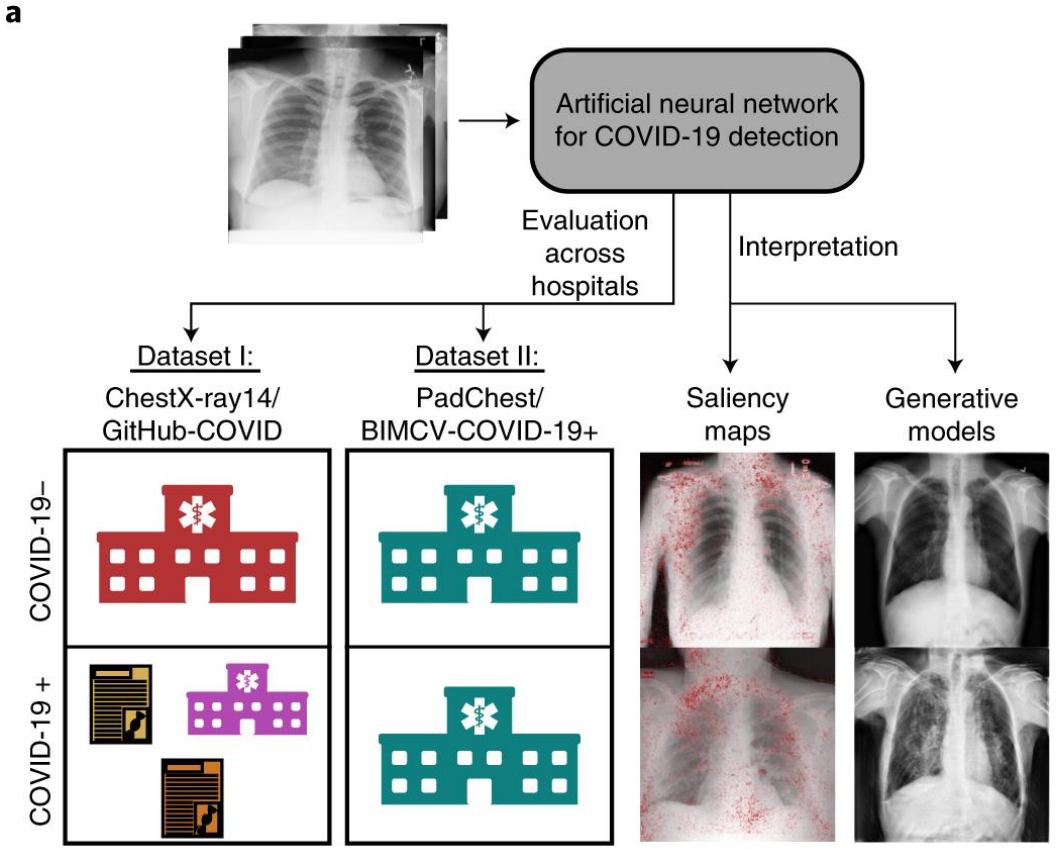
Правильный ответ ≠ правильные причины

Shortcut learning — «эффект умного Ганса»

- Модель идёт по «короткому пути» и ищет побочный признак вместо настоящего
- Работает на тесте, но ломается при смене условий (domain shift)
- Модель читает артефакты разметки
- Обнаружить это можно, только заглянув внутрь модели

Известные примеры

- COVID-19: модель узнавала больницу, а не болезнь (DeGrave et al., 2021)



02 · Виды интерпретации

Классификация методов · примеры визуализаций

Сириус
научно-технологический
университет



Методы-атрибуторы

LIME	SHAP	Int. Grad	Grad-CAM	Occlusion	ISM
agnostic	agnostic	specific	specific	agnostic	agnostic

Сириус
научно-технологический университет

Post-hoc методы: главные семейства

Атрибуции признаков

- Saliency: вклад = градиент выхода по входу
- Integrated Gradients: путь от «базового» входа
- LIME: локальная суррогатная модель
- SHAP: вклады через значения Шэпли

Другие подходы

- Grad-CAM: тепловые карты активаций CNN
- Occlusion: «закрываем» части входа, меряем дельту предсказаний
- ISM —мутации, внедренные в ДНК

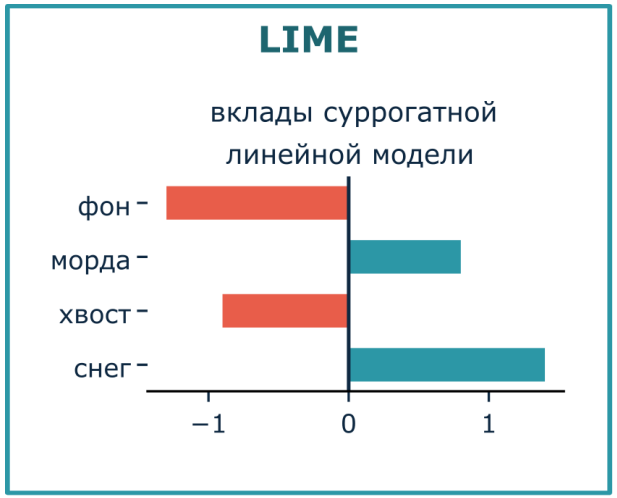
Как выглядят объяснения: 4 семейства

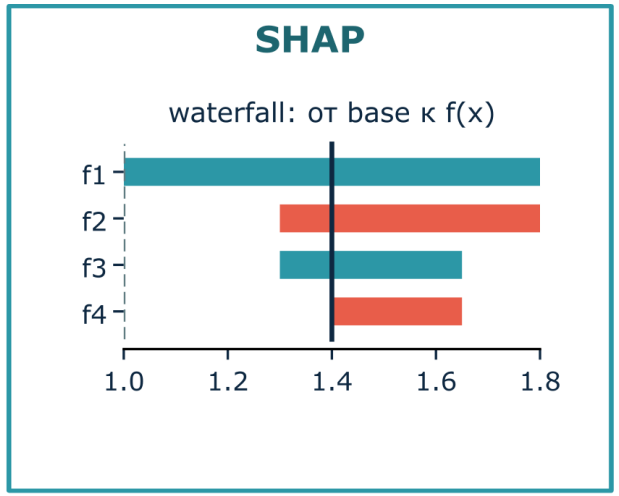
Теория игр

- LIME — локальная линейная модель поверх внесенных изменений
- SHAP — справедливые вклады признаков по теории игр

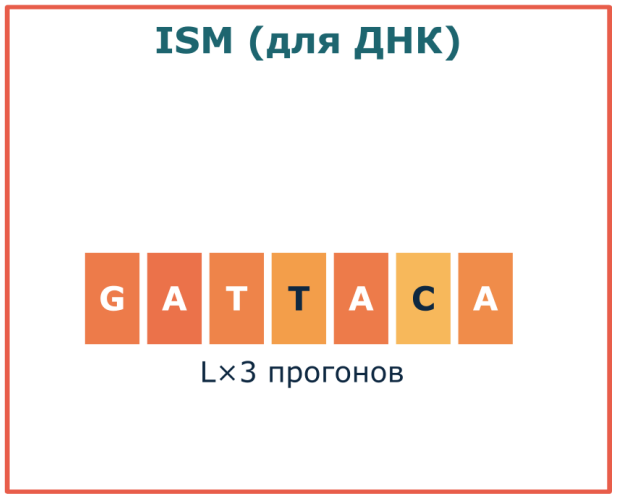
Изменения входа модели

- Occlusion — разница предсказаний при закрытии участка
- ISM — замены нуклеотидов и измерение предсказаний. Главный инструмент для ДНК



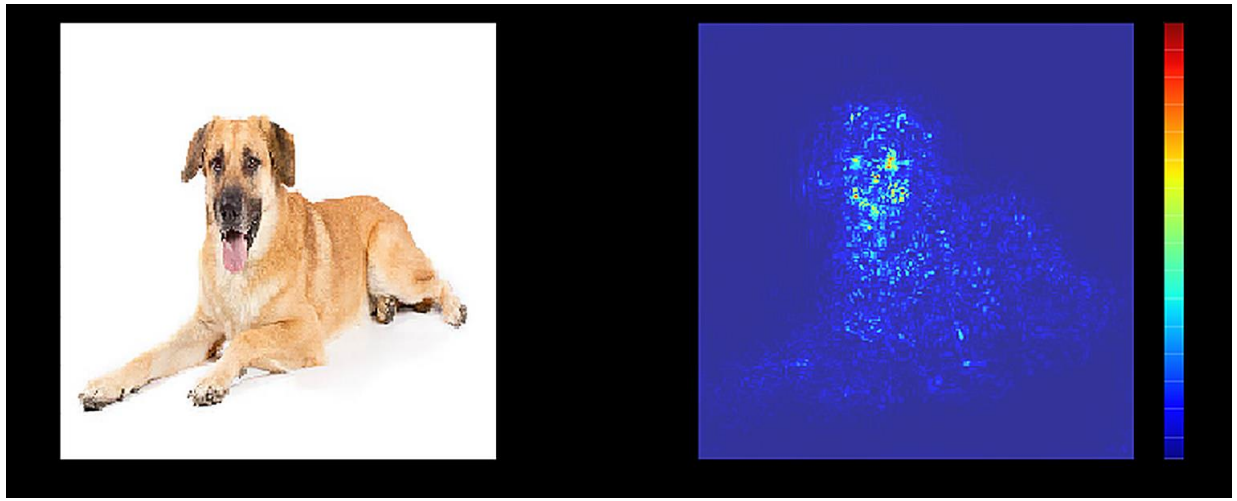






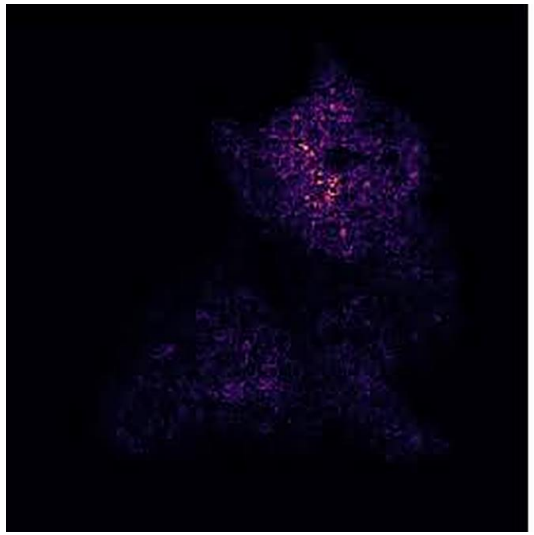
Сириус
научно-технологический университет

Saliency, Integrated Gradients, Grad-CAM



Saliency: карта градиента по входу

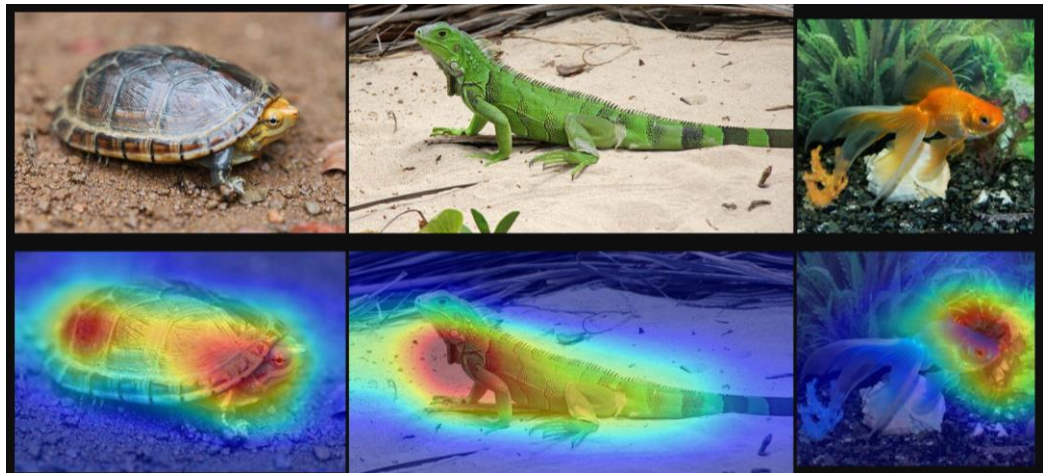
Simonyan et al., 2014





Integrated Gradients: вклады поверх фото

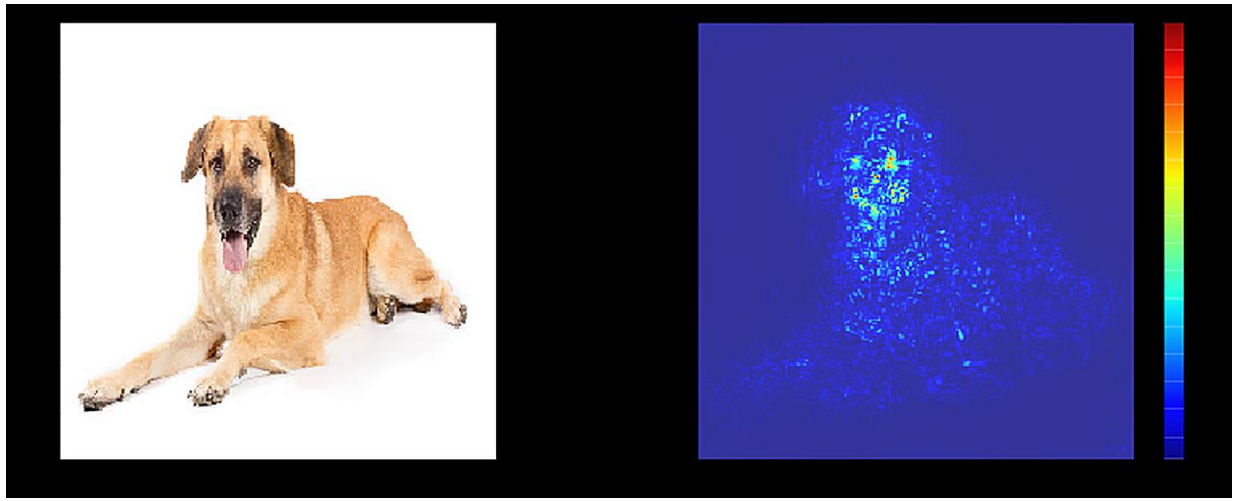
Sundararajan et al., 2017

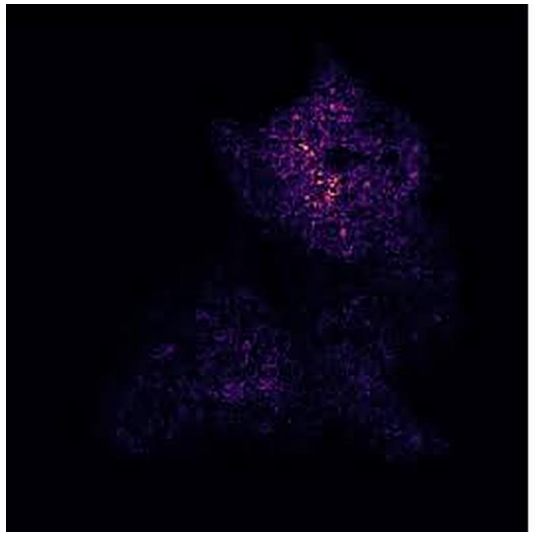


Selvaraju et al., ICCV 2017

Сириус
научно-технологический университет

Saliency, Integrated Gradients, Grad-CAM, ISM





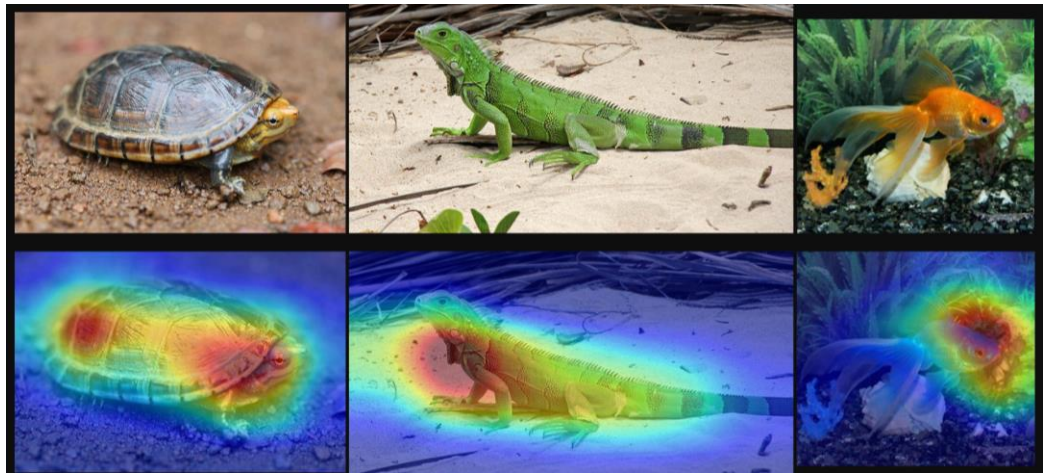


Saliency: карта градиента по входу

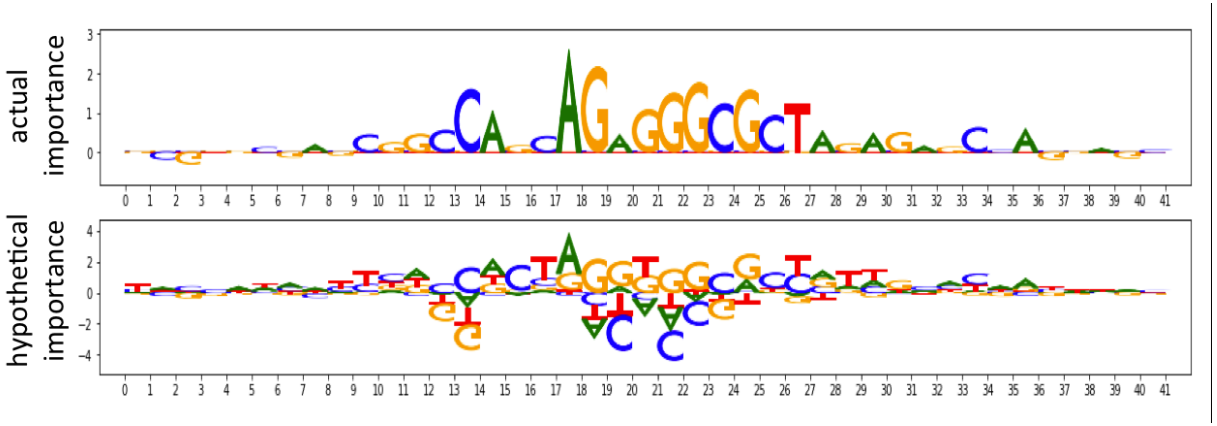
Simonyan et al., 2014

Integrated Gradients: вклады поверх фото

Sundararajan et al., 2017



Selvaraju et al., ICCV 2017



In silico mutagenesis, TF-MoDISco

Anshul Kundaje et. al, 2020

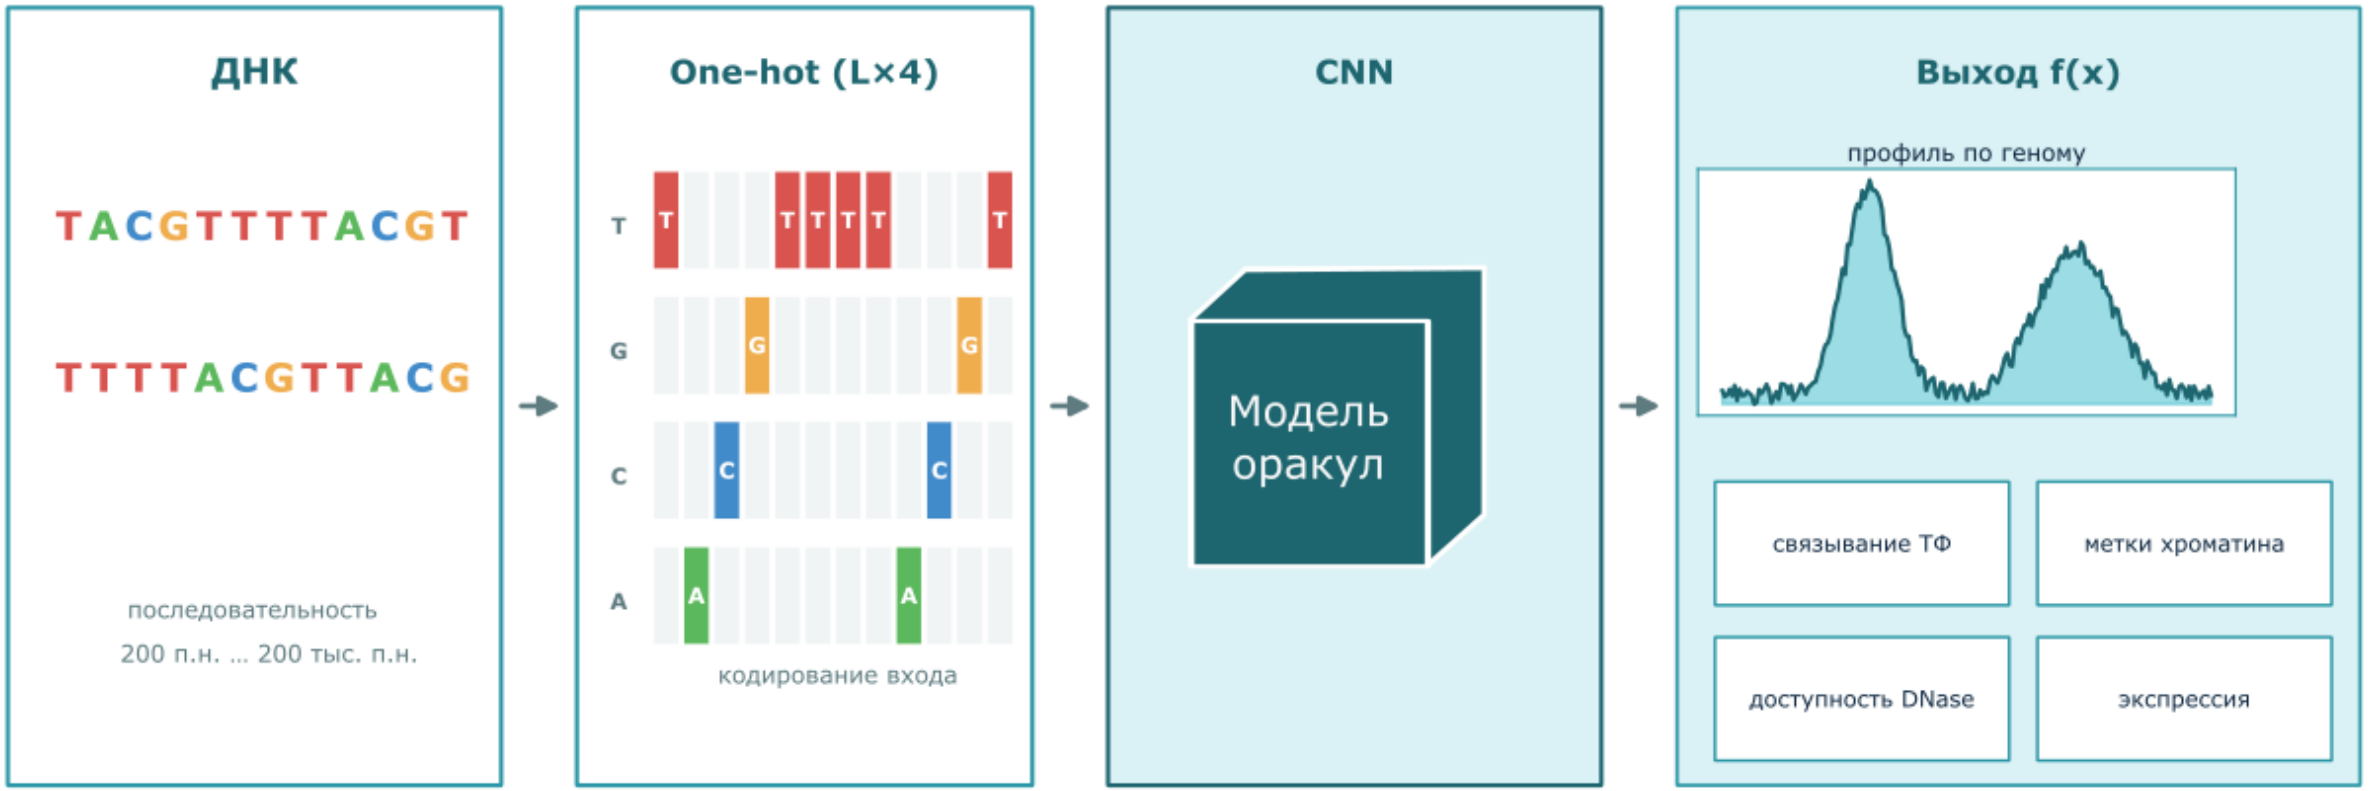
Сириус
научно-технологический университет

03 · Интерпретация в геномике

Свёрточные модели · градиентные атрибуции · мотивы

Сириус
научно-технологический университет

Что мы объясняем в геномике



Сириус
научно-технологический университет

Градиентные атрибуции на ДНК

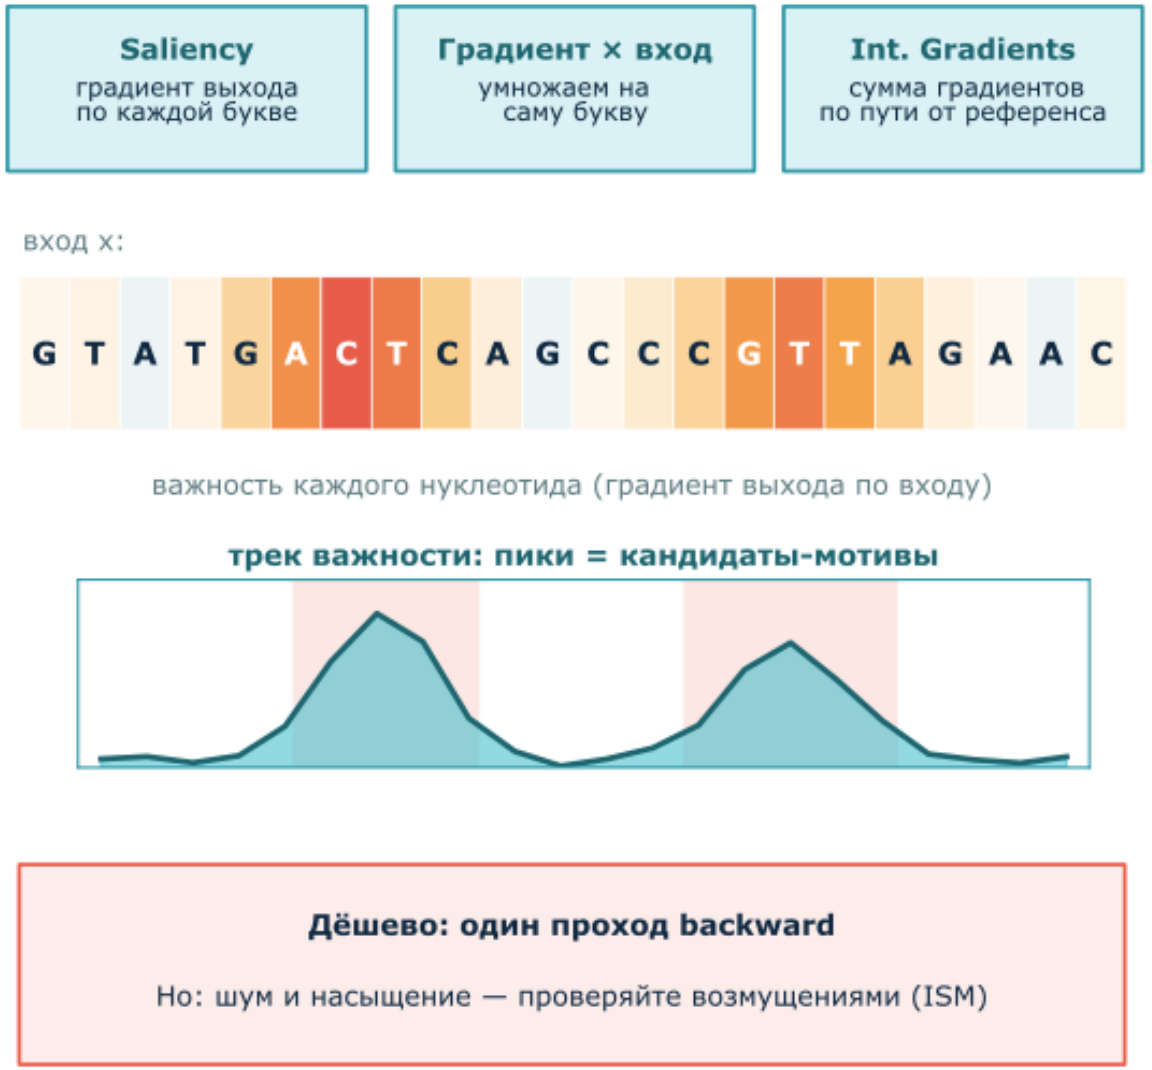
Идея

- важность буквы = градиент выхода по входу
- Saliency: один backward pass — быстро, но шумно

Вариации

- Integrated Gradients: оценивает вклад каждого нуклеотида в предсказание, интегрируя градиенты модели вдоль плавного перехода от выбранного референса к исследуемой ДНК
- DeepLIFT: сравнение с «базовым» входом — без насыщения

- **Инструменты**: tangermeme (2026), Captum



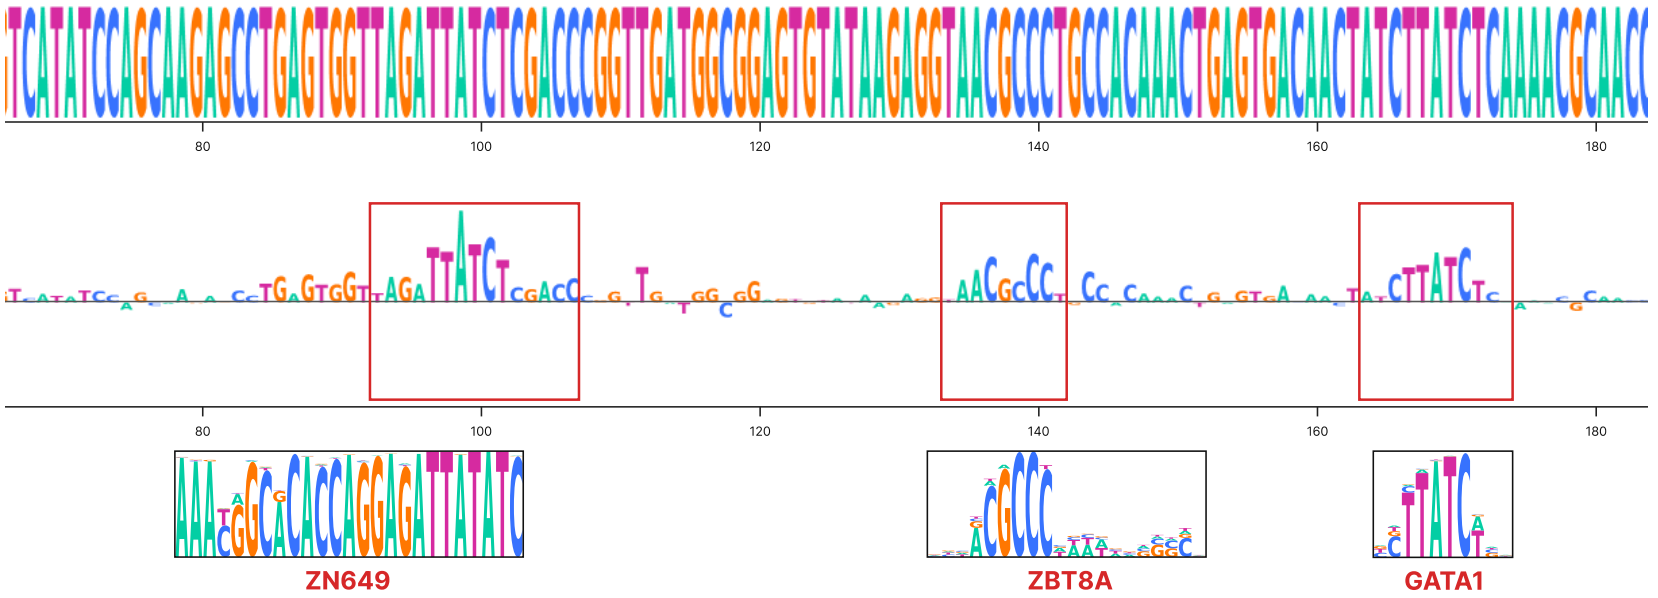
04 · In silico mutagenesis

Прямой вопрос модели: меняем буквы — смотрим на ответ

Сириус
научно-технологический университет

Зачем нужен ISM

- градиент видит только референс, в то время как ISM может отследить эффект всех замен
- **Actual importance**: можно узнать вклады букв референса
- **Hypothetical importance:** эффект каждой замены
- Замены в мотиве резко меняют важность

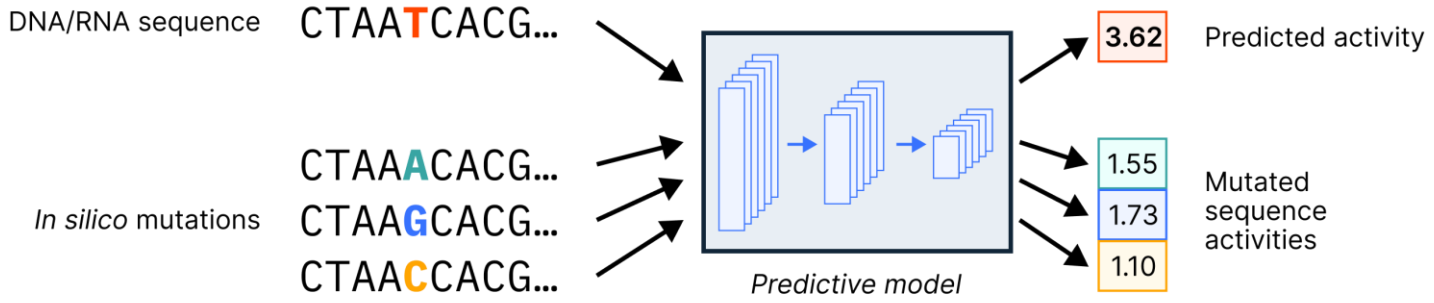


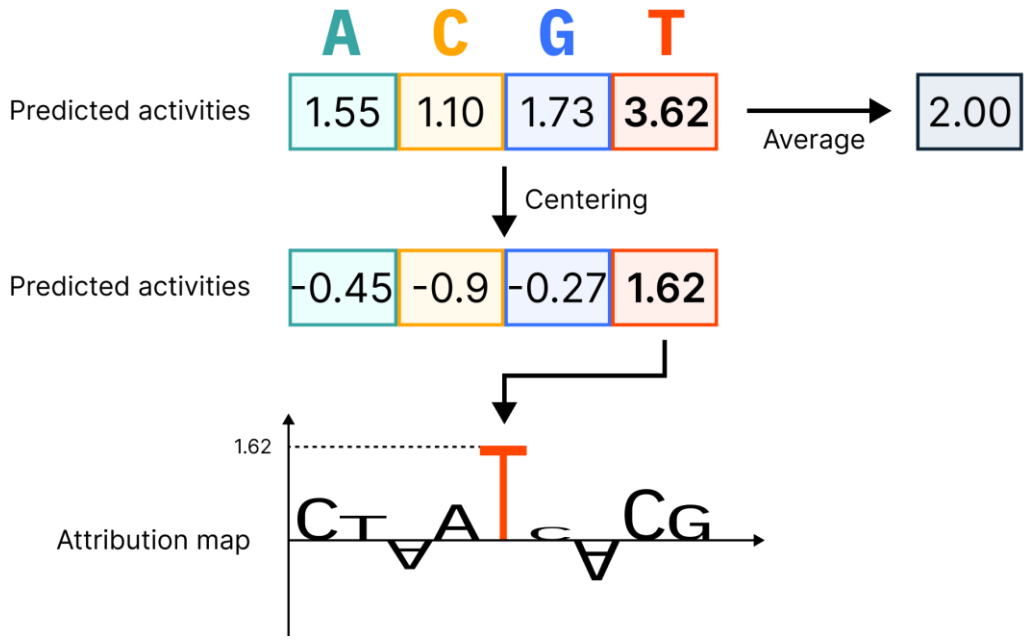
ISM пошагово: алгоритм

sequence-to-function модель: вход ДНК → предсказание экспрессии

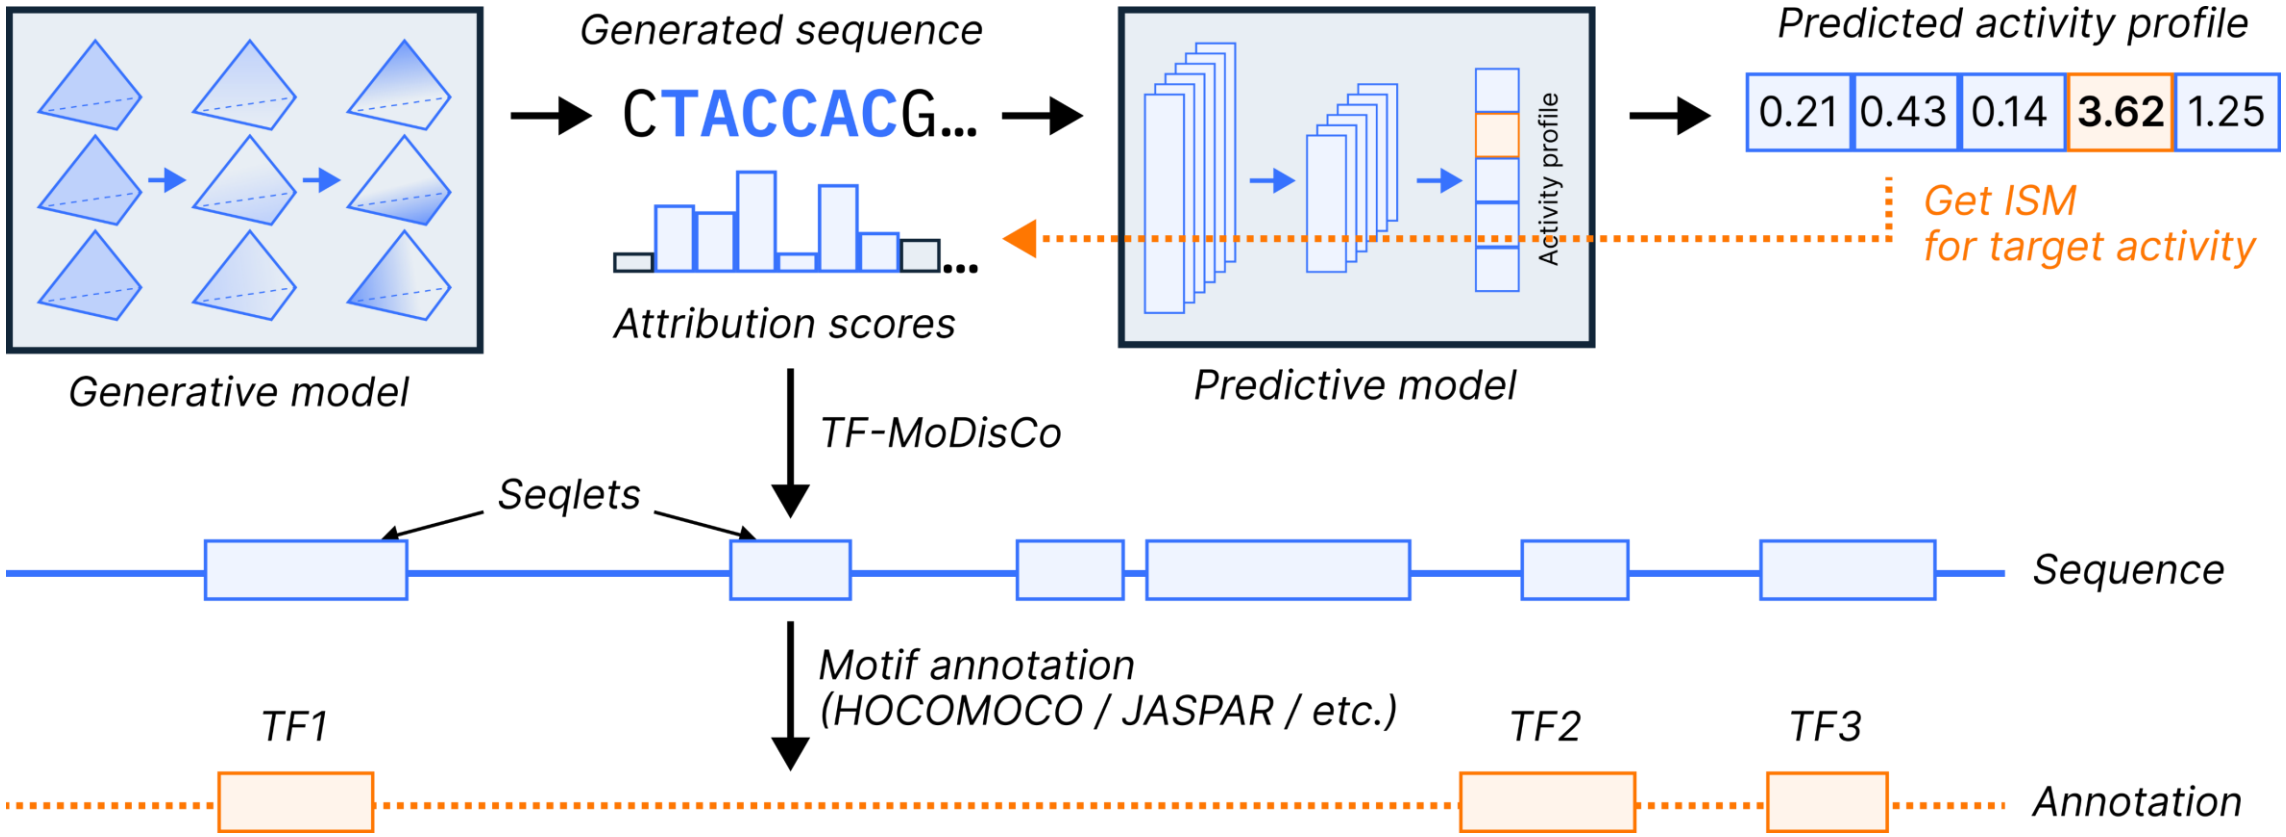
1. Выбираем позицию в исходной последовательности
2. Заменяем нуклеотид поочерёдно на A, C, T, G
3. Модель оценивает активность каждого варианта
4. Вычисляем среднее предсказние для четырёх оснований
5. Определяем вклад основания:
   ISM = предсказание - среднее
6. Повторяем для всех позиций

Интерпретация: положительный ISM повышает предсказанную активность, отрицательный — снижает.





Аннотация


Generative model
Generated sequence
CTACCACG...
Attribution scores
Predictive model
Activity profile
Predicted activity profile
0.21
0.43
0.14
3.62
1.25
Get ISM
for target activity
TF-MoDisCo
Seqlets
Sequence
Motif annotation
(HOCOMOCO / JASPAR / etc.)
TF1
TF2
TF3
Annotation

In silico mutagenesis: ограничения

01

Пределы метода

- 3L прогонов — дорого для длинных входов и геномов
- Одиночные мутации не видят компенсаций (нужны двойные)
- Мутанты «вне многообразия» естественных последовательностей
- Результат зависит от контекста и шума модели

02

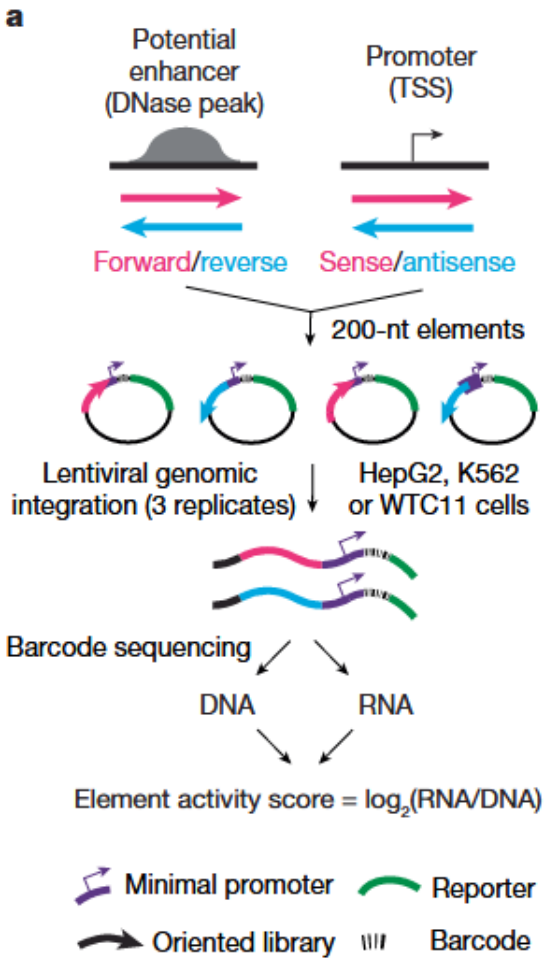
ISM vs градиентные методы

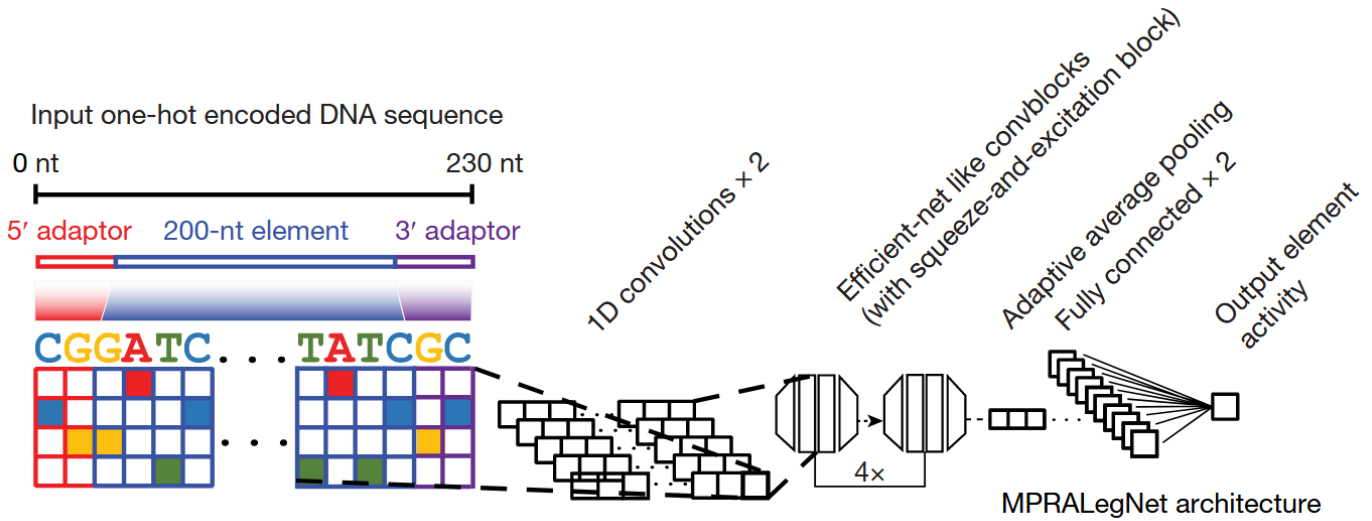
- Градиенты: один backward pass, но шум и насыщение
- ISM — эмпирический «золотой стандарт» проверки атрибуций
- Практика: градиенты для скрининга → ISM для кандидатов
- Согласие независимых методов = доверие

05 · Примеры из статей

LegNet · tangermeme

LegNet и lentiMPRA · Agarwal et al., Nature 2025

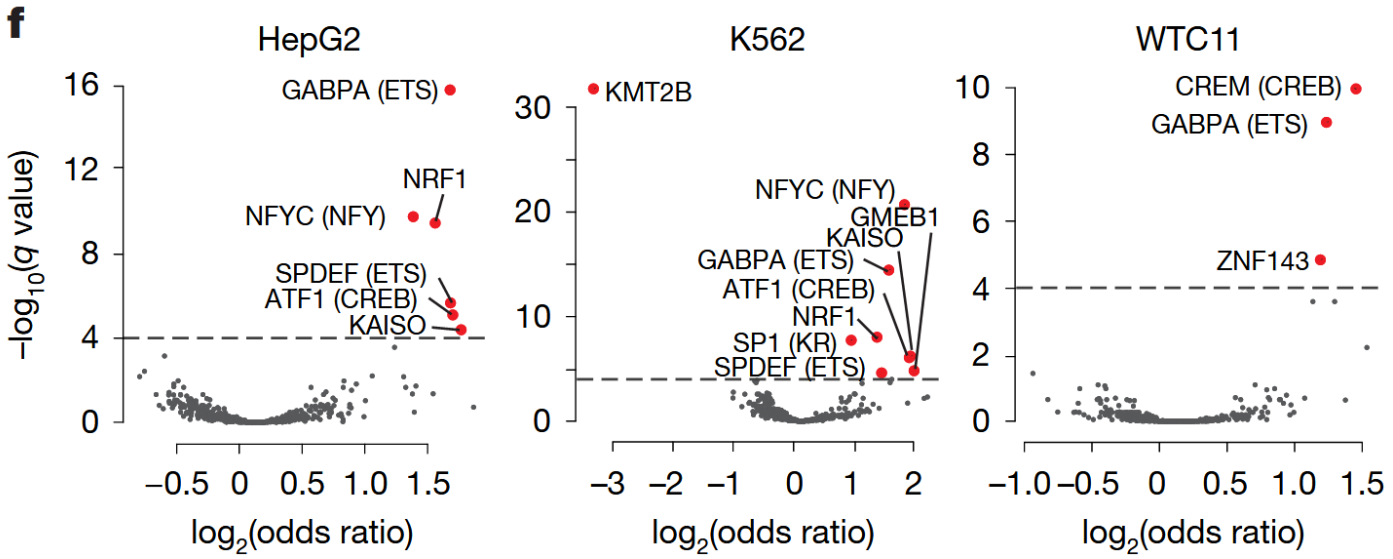


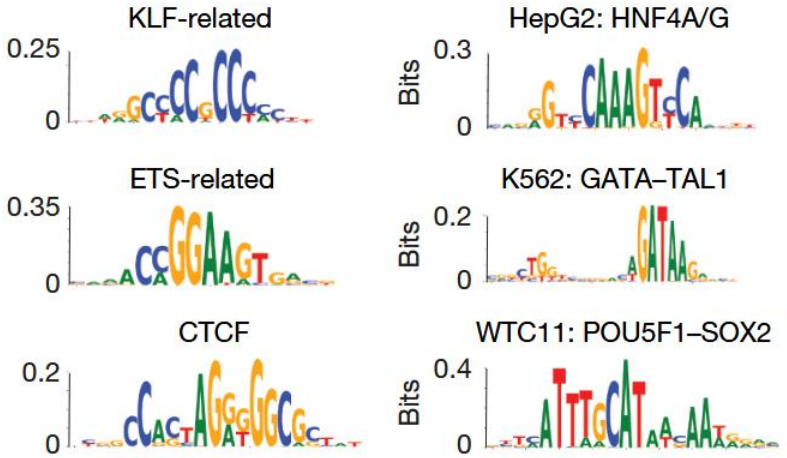


С помощью lentiMPRA измерили регуляторную активность более 680 тысяч ДНК-последовательностей в трёх типах клеток человека

Обучили MPRALegNet предсказывать экспрессию по последовательности

Интерпретация модели позволила выделить регуляторные мотивы и оценить их вклад в клеточно-специфическую активность

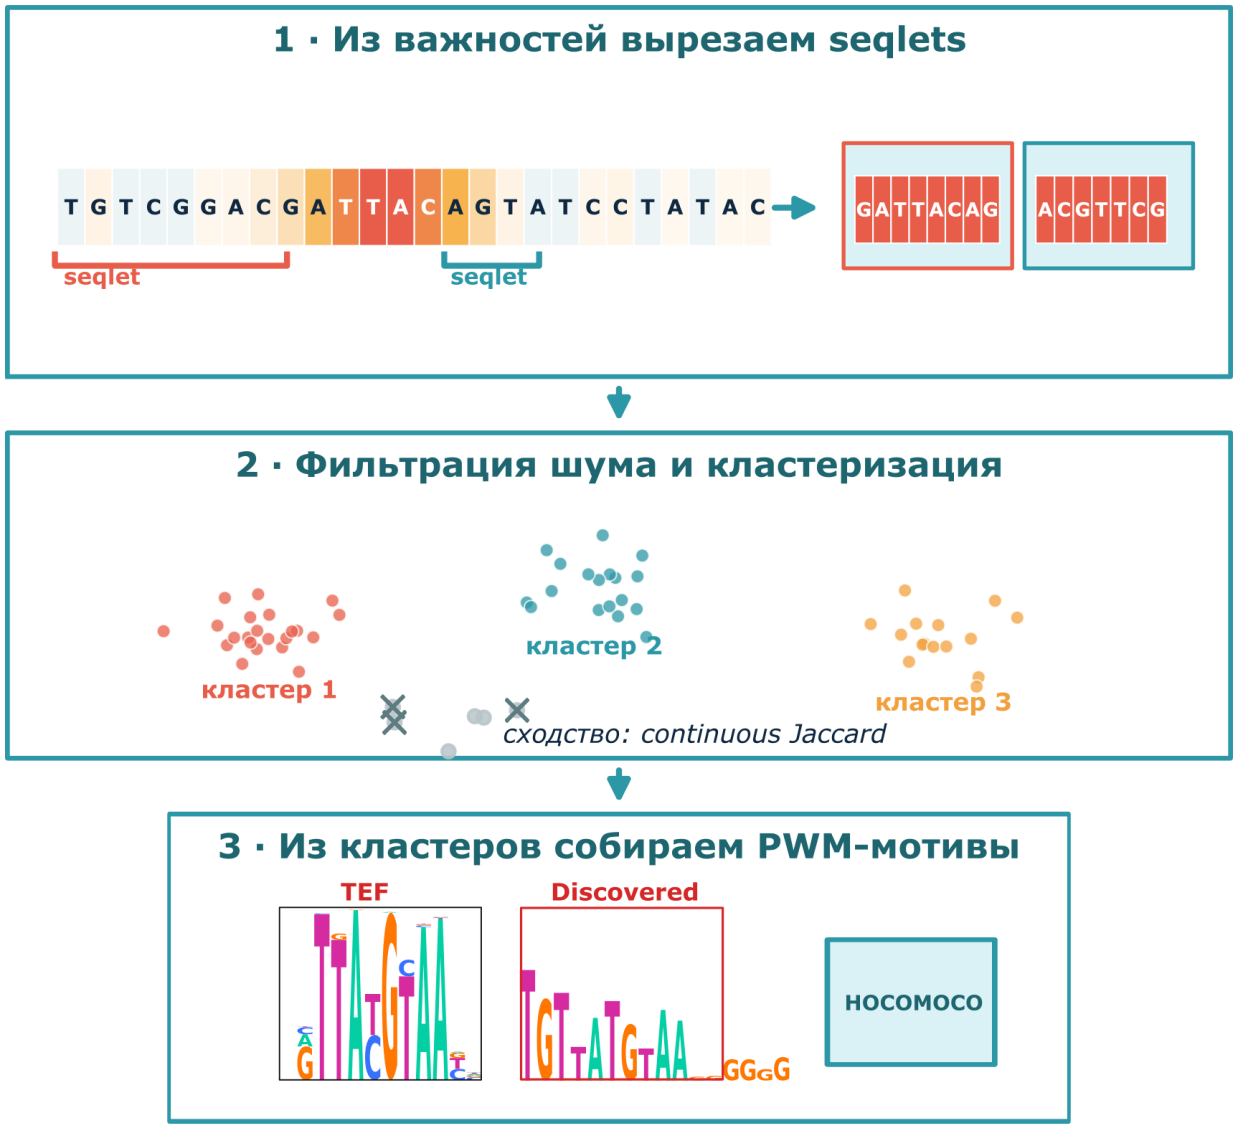




От атрибуций к мотивам: TF-MoDISco

Алгоритм · Shrikumar et al., 2020 · arXiv:1811.00416

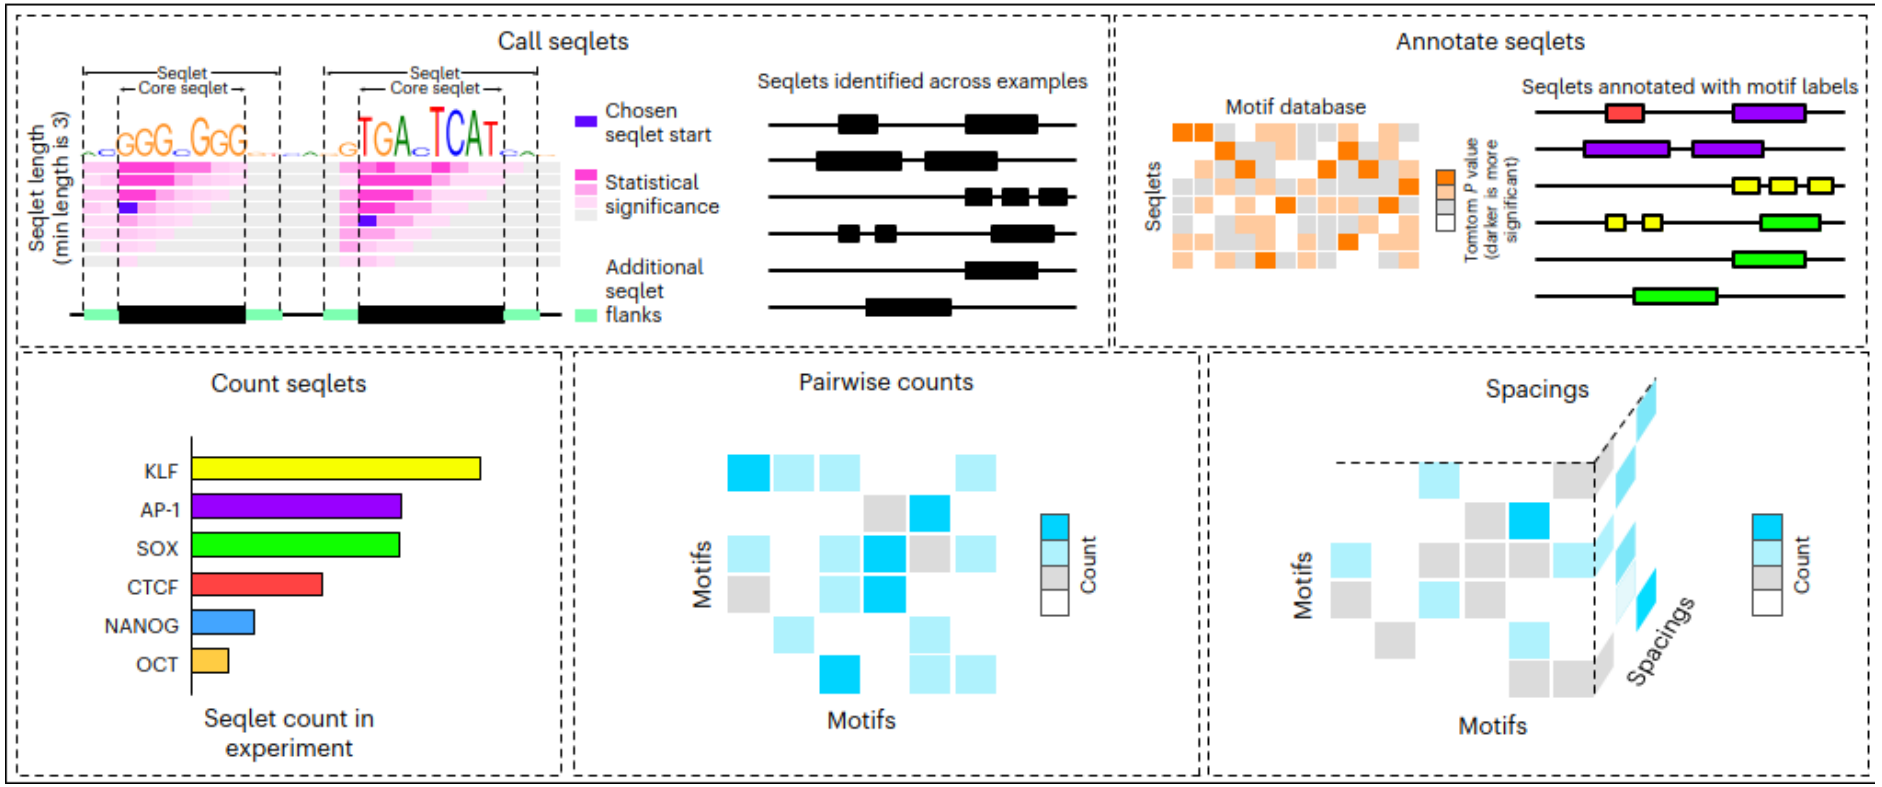
- Атрибуции → seqlets: окна с сильным сигналом
- Фильтрация шума: слабая корреляция отбрасывается
- Кластеризация seqlets (continuous Jaccard)
- Кластеры → PWM-логотипы мотивов
- Сверка с JASPAR / HOCOMOCO



Инструменты: tangermeme · Schreiber, Nature Methods 2026

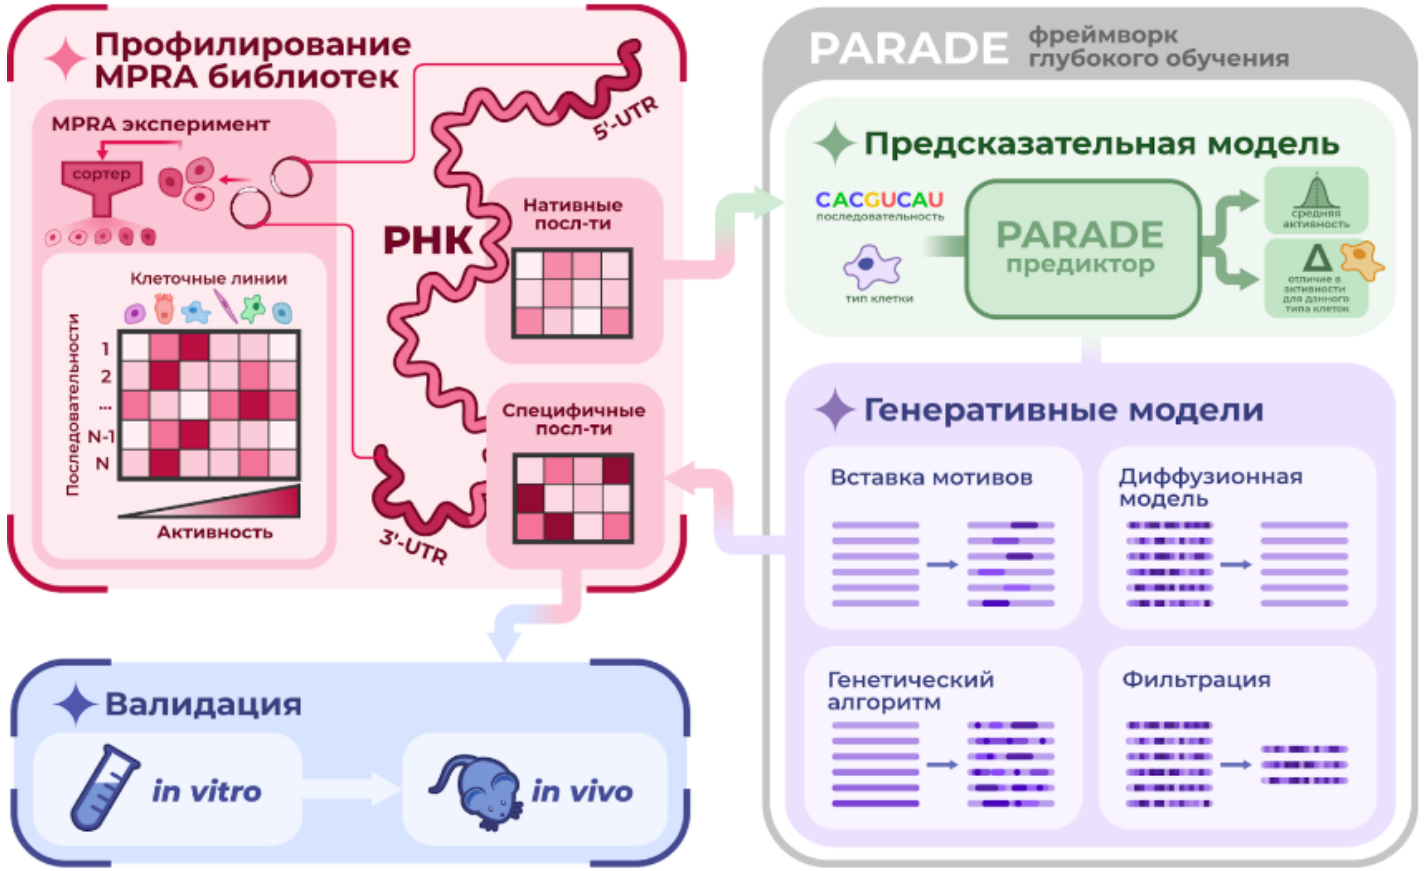
«Everything-but-the-model»

- Единый инструментарий поверх любой геномной модели
- Атрибуции: saliency, градиент×вход, IG, DeepLIFT
- ISM: оптимизированные возмущения, батчи на лету
- TF-MoDISco встроен: важности → мотивы



PARADE: Prediction And Rational Design

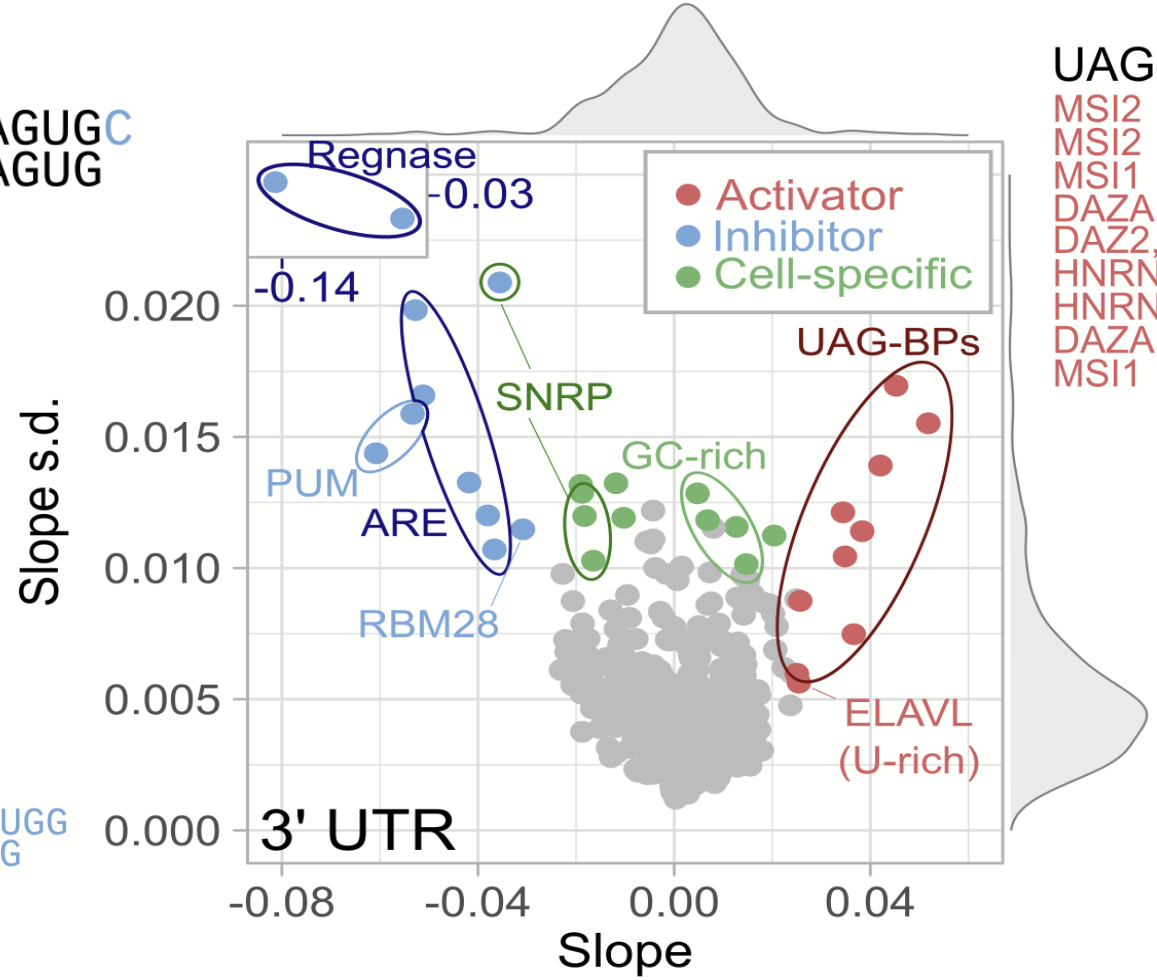
Предсказывает экспрессию по нетранслируемым областям РНК в клеточных линиях



Мотивы играли роль в активности и клеточной специфичности UTR

Regnase:

ZC3H12A,B	GCAGGUAAGUGC
ZC3H12C	AGGUAAGUG



UAG-BPs:

MSI2	GUAGUGUGUAGU
MSI2	GUAGUGGUGUAG
MSI1	GUAGUGGUAG
DAZAP1, HNRNPA0	UUAGGUUAGG
DAZ2,4	GCUCUAGUUAGUAUC
HNRNPA0	UUAGGUUUAGG
HNRNPA1L2, A3	UAGGUUAGGG
DAZAP1	UAGGUAG
MSI1	UAGUUAG

ARE (AU-rich):

ZFP36, ZFP36L1-2	UAUUUAUGGUGG
RBMS1	GUAUUUAUUGG
ZFP36, ZFP36L1-2	UAUUUAUU
ZFP36, ZFP36L1-2	UUAUUUAU
MEX3A,3B	UAUUUAU

Выводы

01

Зачем

- Объяснение = гипотеза + способ её проверить
- Защита от ложного доверия

02

Чем

- Атрибуции + TF-MoDISco = PWM de novo
- ISM — получение аттрибуций “важных элементов”

03

Что дальше

- Методы дополняют друг друга и их комбинация
- Проверка аттрибуций на разных моделях и данных
- Интерпретация как инструмент мотивов

Сириус
научно-технологический университет

Спасибо за внимание!

https://github.com/WenyaWeiss/sirius2026

Практикум

Сириус
научно-технологический
университет